

Breast cancer detection using Convolutional Neural Network and Transfer Learning

Projekat iz Računarske inteligencije
Matematički fakultet
Univerzitet u Beogradu

Septembar 2023

Contents

1	Uvod	3
2	Opis problema	3
3	Skup podataka	3
4	Pretprocesiranje	3
5	Metrike	3
6	Model zasnovan na konvolutivnoj neuronskoj mreži	4
7	VGG16 model	4
8	VGG16 model od nule	4
9	Literatura	6

1 Uvod

Konvolutivne neuronske mreže (eng. Convolutional Neural Networks – CNNs) predstavljaju aktuelan i istraživački atraktivan domen u širokoj oblasti veštačke inteligencije. CNNs su biološki inspirisana verzija višeslojnog perceptrona (eng. Multilayer Perceptron – MLP). Prema svojoj arhitekturi CNNs se mogu svrstati u duboke neuronske mreže (eng. deep neural networks), za koje se vezuje pojam dubokog učenja (eng. Deep Learning – DL). Duboke arhitekture neuronskih mreža pokazale su veliki značaj i dale doprinos u rešavanju naizgled, za jednu mašinu, nerešivih problema. CNN sačinjava jedan ili više konvolucionih slojeva i opciono jedan ili više potpuno povezanih (eng. Fully Connected – FC) slojeva. CNNs su projektovane tako da prednost postižu u radu sa 2D strukturama, kao što su slike ili ulazi poput govornog signala, a u najnovijim studijama se pokazuje da postižu značajne rezultate i sa 3D strukturama. Međutim treniranje dubokih neuronskih mreža je zahtevan proces koji koristi mnogo resursa. Malo naprednija tehnika dubokog učenja je transfer learning. Ova tehnika koristi težine iz prethodno obučanih modela u izradi novog modela. U transfer learningu, dakle pokušavamo da iskoristimo ono što je naučeno u jednom problemu kako bismo poboljšali generalizaciju u drugom. Ova tehnika se temelji na ideji da modeli koji su već naučili parametre iz velikih skupova podataka mogu preneti to znanje na slične zadatke, čime se ubrzava proces treniranja i poboljšava performanse modela.

2 Opis problema

Bolest raka dojke drugi je najčešći uzrok smrti od raka u svijetu kod žena. Međutim, rana dijagnostika i otkrivanje mogu značiti značajnu šansu za pravilno liječenje i preživljavanje. Razvijamo model koji na osnovu slika tkiva dojke može prepoznati maligne promene i razlikovati ih od benignih promena. To je problem klasifikacije slika sa dve klase: benigni i maligni. Uobičajeni medicinski postupak dijagnoze raka dojke uključuje skupe i dugotrajne histopatološke analize, stoga postoji potreba za brzim, automatskim i što preciznijim rešenjima za rano otkrivanje malignog tkiva.

3 Skup podataka

Korišćen je skup podataka Breast Cancer Histopathological Database (BreakHis) koji je preuzet sa <https://www.kaggle.com/datasets/ambarish/breakhis>. BreakHis se sastoji od 9.109 mikroskopskih slika tkiva dojke sakupljenih od 82 pacijenta koristeći različite faktore povećanja (40X, 100X, 200X i 400X). Trenutno sadrži 2.480 benignih i 5.429 malignih uzoraka (700x460 piksela, RGB format sa 3 kanala, 8-bitna dubina u svakom kanalu, PNG format). Iz naziva slika izvučene su tačne klase za svako tkivo. Sve slike iz originalnog dataset-a prebačene su u prvo u jedan folder. Urađena je podela podataka na tri skupa: trening, test i validacioni. Zatim su podaci podeljeni u šest foldera tako da su odvojene klase (malignant i benign) za sva tri skupa podataka. Ovo je izvršeno kako bi u nastavku bilo omogućeno korišćenje ImageDataGenerator-a.

4 Pretprocesiranje

Korak pretproseciranja je bitan zbog transformacije slika u format pogodan za model. Korišćena je augmentacija podataka sa Keras ImageDataGenerator klasom kako bismo izmenili naš skup podataka i tako poboljšali treniranje modela. ImageDataGenerator se često koristi za poboljšanje generalizacije i otpornosti modela na različite varijacije u ulaznim podacima. Kao transformaciju dozvoljeno je koristiti variranje osvetljenja slika u okviru zadatog raspona, zumiranje slike do 10%, slučajna rotacija slika za do 10 stepeni, horizontalno i vertikalno pomeranje slika za do 10%, kao i horizontalno i vertikalno rotiranje slika.

5 Metrike

Postoji nekoliko mera koje se koriste za prikazivanje performansi rezultata klasifikacije, mi smo uzeli u obzir sledeće četiri:

$$Tačnost = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Preciznost = \frac{TP}{TP + FP}$$

$$Odziv = \frac{TP}{TP + FN}$$

$$f1\text{-skor} = \frac{2 * (Preciznost * Odziv)}{(Preciznost + Odziv)}$$

TP: Tačno Pozitivne, TN: Tačno Negativne

FP: Lažno Pozitivne i FN: Lažno Negativne.

Tačnost - (Accuracy) je osnovna metrika koja se koristi za evaluaciju modela, opisuje broj tačnih predviđanja u odnosu na ukupan broj predviđanja. Poželjno postići tačnost veću od 90%.

Preciznost - (Precision) je mera koliko su tačna pozitivna predviđanja koja su napravljena.

Odziv - (Recall) je mera koliko je klasifikator tačno predvideo pozitivne slučajeve u odnosu na ukupan broj pozitivnih slučajeva u podacima.

f1-skor - (f1-score) je mera koja ravnotežno vrednuje dva odnosa: Preciznost i Odziv.

f1-skor može imati vrednost od 0 do 1, pri čemu je 0 najgora moguća vrednost, a 1 najbolja.

Vrednost 1 predstavlja da je model savršeno klasifikovao svako posmatranje u ispravnu klasu.

6 Model zasnovan na konvolutivnoj neuronskoj mreži

Ovaj model je osmišljen za klasifikaciju slika u dve klase (maligna i benigna). Sastoji se iz Conv2D, MaxPooling, Flatten i Dense slojeva. Konvolutivni slojevi se koriste za ekstrakciju karakteristika iz slika, a potpuno povezani slojevi za donošenje klasifikacijskih odluka. Dropout slojevi pomažu u sprečavanju prenaučivosti i poboljšavaju generalizaciju modela. Model koristi i sistem za rano zaustavljanje (early stopping) koji prati val loss i potencijalno može zaustaviti treniranje ranije ukoliko zaključuje da se dodatnim treniranjem neće postići bolji rezultat.

7 VGG16 model

Za potrebe transfer learning-a korišćen je VGG16 koji dolazi sa bibliotekom Keras i koristi imagenet težine. VGG16 je model konvolucijske neuronske mreže koji postiže tačnost od 92,7% u bazi podataka ImageNet koja sadrži preko 14 miliona slika koje se razvrstavaju u preko 1000 klasa. Izbacen je gornji sloj i isključeno treniranje baznom modelu, a potom dodati BatchNormalization, Dropout slojevi, kao i finalni Dense koji za svaku klasu vrši predviđanje.

8 VGG16 model od nule

Radi poređenja smo trenirali istu arhitekturu kao u predhodnom primeru ali ovog puta model je od nule trenirao sve parametre i oni nisu bili zaključani. Dodati su isti slojevi nakon uklanjanja gornjeg sloja.




Figure 1: Tacnost i gubitak




Figure 2: ROC kriva




Figure 3: Matrica konfuzije




Figure 4: Tacnost i gubitak




Figure 5: ROC kriva




Figure 6: Matrica konfuzije




Figure 7: Tacnost i gubitak




Figure 8: ROC kriva




Figure 9: Matrica konfuzije

9 Literatura

- [1] [Materijali iz Računarske inteligencije](#)
- [2] [Boosting Breast Cancer Detection Using Convolutional Neural Network](#)
- [3] [Development of Breast Cancer Detection Model Using Transfer Learning of Residual Neural Network \(ResNet-50\)](#)